

UNIVERSIDAD AUTONOMA DE SINALOA



Licenciatura en Informática

Materia: OPT. Cómputo en la nube, redes sociales
y aplicaciones compuestas

Prof. Oscar Mejía Quintero

Alumnos:

Corvera Quevedo Jhonan Ismael

Galindo Meléndrez Raúl Caleb

Galindo Meléndrez Sergio Jesús

Higuera Medina Jocelyn Guadalupe

Grado y grupo: 5-2

Tema: Proyecto de MongoDB:

Analítica Distribuida Aplicada a la Prevención de Incendios

Fecha: 19/01/2026

Link de Evidencias:

<https://drive.google.com/drive/folders/1xDZgoMby2nvdKPL6k3HnhnCZbfnI91-N?usp=sharing>



Contenido

Introducción.....	3
Problemática	4
Justificación de Selección de la Institución.....	5
Propuesta de Solución	5
Justificación de la Arquitectura	6
Procesamiento Avanzado con Apache Spark.....	7
Diseño y Carga de la Base de Datos	8
Ejecución del Modelo MapReduce	9
Interpretación de los Resultados	10
Conclusiones.....	11
Anexos.....	12
Resultados de Impacto Ambiental (Promedios)	12
Detalles de la Infraestructura.....	12
Guía de Configuración del Entorno (Ubuntu)	12
Diccionario de Datos y Esquema NoSQL	13
Glosario Técnico y Resultados Extendidos	13
Tabla de Resultados de Impacto por Ecosistema	14
Referencias Bibliográficas	15

Introducción

La Secretaría de Medio Ambiente y Recursos Naturales (SEMARNAT) es la institución del gobierno mexicano responsable de la protección, restauración y conservación de los ecosistemas y recursos naturales del país. Entre sus tareas más críticas se encuentra la prevención y combate de incendios forestales, labor que coordina a través de la Comisión Nacional Forestal (CONAFOR). La magnitud de estos siniestros y la velocidad con la que se propagan exigen herramientas tecnológicas avanzadas que superen las limitaciones de los sistemas de información tradicionales.

Este proyecto de investigación plantea una solución basada en arquitecturas de Big Data para fortalecer la vigilancia y detección temprana de incendios y deforestación. El uso de bases de datos NoSQL como MongoDB y motores de procesamiento distribuido como Apache Spark y MapReduce permite gestionar grandes volúmenes de datos climáticos, satelitales y de sensores en tiempo real. El objetivo es desarrollar un marco técnico que proporcione información precisa para la toma de decisiones, contribuyendo así a la preservación del patrimonio natural de México.

Palabras clave: MongoDB, Spark, MapReduce, BigData, Incendios, Patrones, Distribución

Problemática

En México, la gestión de incendios forestales representa un desafío crítico para la SEMARNAT. Tan solo en el último ciclo, entidades como el Estado de México registraron cientos de incidentes individuales, lo que demuestra que la frecuencia de los incendios es masiva.

El problema central no es solo la detección, sino la capacidad de respuesta. Los sistemas actuales a menudo dependen de reportes humanos o procesamiento manual de imágenes, lo que genera un retraso fatal. Al enfrentarnos a una gran cantidad de datos provenientes de diversas regiones al mismo tiempo, los sistemas tradicionales no pueden identificar patrones de riesgo (como la combinación de baja humedad y altas temperaturas) con la velocidad necesaria para prevenir que un pequeño conato se convierta en un incendio incontrolable de miles de hectáreas.

Evidencia: Trabajamos con datos reales y masivos de la SEMARNAT.



Justificación de Selección de la Institución

La elección de la SEMARNAT se fundamenta en su papel crítico como garante de la seguridad ambiental de México. A diferencia de un sector comercial, la gestión de los recursos naturales tiene un impacto directo en la soberanía y estabilidad social.

Ejes de relevancia nacional:

1. **Seguridad Nacional:** El uso de Big Data permite transitar de un modelo reactivo a uno preventivo.
2. **Impacto Económico:** La detección temprana reduce drásticamente el gasto público en mitigación.
3. **Metas 2030:** Cumplimiento de estándares internacionales de monitoreo ambiental.
4. **Salud Pública:** Reducción de la incidencia de enfermedades respiratorias por humo (partículas PM2.5).


Propuesta de Solución

Para abordar la problemática de la detección temprana de incendios, planteamos una arquitectura de Big Data distribuida en tres capas principales que permiten el manejo eficiente de grandes volúmenes de información. En la capa de ingesta y almacenamiento, los datos provenientes de diversas fuentes, como sensores de temperatura de la CONAFOR y estaciones meteorológicas, son recolectados y enviados a un sistema de almacenamiento no relacional. Seleccionamos MongoDB como base de datos debido a su esquema flexible basado en documentos JSON, lo que permite almacenar datos heterogéneos sin la rigidez de una estructura tabular tradicional. En la capa de procesamiento, implementamos MapReduce para el análisis por lotes de datos históricos y Apache Spark para el procesamiento en memoria, lo cual permite detectar anomalías térmicas con mayor velocidad. Finalmente, en la capa de análisis y visualización, los resultados se transforman en indicadores clave de rendimiento y mapas de calor para la toma de decisiones estratégica.

Justificación de la Arquitectura

La elección de esta arquitectura sobre un sistema de gestión de bases de datos relacionales tradicional se justifica por la necesidad de manejar el volumen, la velocidad y la variedad de los datos de incendios forestales. MongoDB permite una estructura flexible que facilita la división de la información en colecciones lógicas, lo cual es vital debido a que la naturaleza de los datos climáticos suele ser semiestructurada. Por su parte, MapReduce es una herramienta eficiente para generar resúmenes estadísticos anuales sin saturar los recursos del sistema. Finalmente, Apache Spark representa el motor de alta velocidad que elimina la latencia de lectura y escritura en disco al procesar datos directamente en la memoria RAM. Esta combinación asegura que la SEMARNAT pueda transformar datos brutos en información accionable para la protección de los ecosistemas.

Evidencia: Base de datos en MongoDB Compass.



The screenshot shows the MongoDB Compass interface. On the left, the 'CONNECTIONS' panel lists the connected database 'registro_incendios' and its collections: 'incendios_ecologia', 'incendios_identificacion', 'incendios_metricas', 'reporte_vegetacion', and 'resumen_incendios_estado'. The main panel displays a table of collections for the 'registro_incendios' database.

Collection name	Properties	Storage size	Documents	Avg. document size	Indexes	Total index size
incendios_ecologia	-	20.48 kB	100	160.00 B	1	20.48 kB
incendios_identificacion	-	24.58 kB	100	148.00 B	1	20.48 kB
incendios_metricas	-	20.48 kB	100	121.00 B	1	20.48 kB
reporte_vegetacion	-	20.48 kB	16	85.00 B	1	20.48 kB
resumen_incendios_estado	-	20.48 kB	23	39.00 B	1	20.48 kB


Procesamiento Avanzado con Apache Spark

Para el análisis de alto rendimiento, utilizamos Apache Spark aprovechando su capacidad de procesamiento en memoria. El flujo de trabajo consistió en establecer conexiones individuales para los DataFrames de identificación, ecología y métricas cargados desde MongoDB. Debido a que la información estaba normalizada en diferentes colecciones, realizamos una operación de Join utilizando el campo clave_incendio como llave común, consolidando en un solo objeto los datos geográficos y el impacto ambiental. Posteriormente, aplicamos funciones de agrupamiento y agregación para calcular el promedio de hectáreas afectadas por tipo de vegetación. Los resultados finales fueron persistidos de vuelta en la base de datos en una nueva colección denominada reporte_vegetacion, garantizando que el conocimiento generado sea accesible para futuras consultas.

Evidencia: Tabla final que imprimió Spark.

```
¡Todas las colecciones han sido cargadas en Spark!
Unión completada. Ahora tenemos todos los datos en un solo DataFrame.
Promedio de hectáreas quemadas por tipo de vegetación:
+-----+-----+
|vegetacion|promedio_hectareas|
+-----+-----+
|Chaparral|144.232|
|Selva Mediana Sub...|98.59333333333332|
|Matorral Desértic...|84.19|
|Bosque de Encino|47.01657|
|Bosque de Pino-En...|37.00588235294118|
|Selva Baja Caduci...|27.343536363636364|
|Bosque Mesófilo d...|24.67|
|Tular|21.584|
|Popal|15.72|
|Bosque de Pino|13.415071428571428|
|Matorral Desértic...|10.525|
|Bosque de Encino...|7.671666666666667|
|Pastizal Natural|5.475|
|Bosque de Oyamel|3.9|
|Bosque de Tásate|3.0|
|Matorral Submontano|0.581|
+-----+-----+
¡Resultados persistidos en MongoDB!
```

Evidencia: colección reporte_vegetacion en MongoDB



Diseño y Carga de la Base de Datos

El desarrollo técnico comenzó con la normalización de los datos obtenidos del archivo estadístico de la CONAFOR, organizándolos en tres colecciones lógicas: identificación, ecología y métricas. La colección de identificación almacena la ubicación geográfica y el año; la de ecología contiene detalles sobre la vegetación y causas; y la de métricas registra el daño cuantitativo. Para la carga de estos datos, desarrollamos un script en Python que utilizó la biblioteca pandas para el manejo de archivos y pymongo para la comunicación con el servidor en la dirección IP 172.28.140.224. Implementamos una lógica de muestreo aleatorio para seleccionar registros representativos, asegurando que los análisis posteriores presenten una diversidad real de los diversos estados de la República Mexicana.

Colección	Contenido Principal	Propósito
identificación	Clave del incendio, año y ubicación	Identificación geográfica
ecología	Tipo de vegetación e impacto	Análisis del contexto ambiental
métricas	Total de hectáreas y duración	Medición cuantitativa del daño

Evidencia: fragmentos del script que hace el muestreo aleatorio con el comando `df.sample(100)` y las líneas donde se definen las tres colecciones de destino.


```
Definir las colecciones
identificacion = db['incendios_identificacion']
ecologia = db['incendios_ecologia']
metricas = db['incendios_metricas']
# Tomamos 100 registros al azar para tener variedad de estados mx
df_100 = df.sample(n=100)
registros = df_100.to_dict(orient='records')

# Listas para clasificar los datos en las 3 colecciones
docs_identificacion = []
docs_ecologia = []
docs_metricas = []
```


Ejecución del Modelo MapReduce


Una vez almacenada la información, ejecutamos el modelo de programación MapReduce para realizar un conteo masivo de incendios agrupados por entidad federativa. La función de mapeo se encargó de extraer el nombre del estado de cada documento en la colección de identificación, mientras que la función de reducción consolidó estos registros para entregar un total final por estado. Este método de procesamiento distribuido es fundamental para identificar patrones de recurrencia geográfica a gran escala sin comprometer el rendimiento del servidor principal, proporcionando a la SEMARNAT una visión clara de las zonas con mayor incidencia histórica.

Evidencia: Muestra los resultados del conteo por estados.



```
1 from pymongo import MongoClient
2 from bson.code import Code
3
4 # 1. Conexión al servidor
5 # Usa la IP de tu instancia de Ubuntu
6 cliente = MongoClient("mongodb://172.28.140.224:27017/")
7 db = cliente['registro_incendios']
8 coleccion = db['incendios_identificacion']
9
10 # 2. Función de Mapa (Map)
11 # Emite el estado como llave y el número 1 como valor
12 map_func = Code("""
13 function() {
14     if (this.ubicacion && this.ubicacion.estado) {
15         emit(this.ubicacion.estado, 1);
16     }
17 }
18 """)
19
20 # 3. Función de Reducción (Reduce)
21 # Suma todos los '1' recibidos para cada estado
22 reduce_func = Code("""
23 function(key, values) {
24     return Array.sum(values);
25 }
26 """)
27
28 # Ejecución de MapReduce
29 map_reduce = coleccion.map_reduce(map_func, reduce_func,
30                                   {'out': 'resumen_incendios_estado'})
```

sergiogalindo@sergiogalindo:~/proyecto_incendios_bigdata\$ source /home/sergiogalindo/proyecto_incendios_bigdata/venv/bin/activate
(venv) sergiogalindo@sergiogalindo:~/proyecto_incendios_bigdata\$ python analisis_mapreduce.py
Iniciando procesamiento MapReduce...
¡Procesamiento completado!
Busca la colección 'resumen_incendios_estado' en MongoDB Compass.



Document
<pre>{ "_id": "Ciudad de México", "value": 12 }</pre>
<pre>{ "_id": "Oaxaca", "value": 2 }</pre>
<pre>{ "_id": "Jalisco", "value": 12 }</pre>
<pre>{ "_id": "Baja California", "value": 2 }</pre>
<pre>{ "_id": "Tlaxcala", "value": 3 }</pre>
<pre>{ "_id": "Durango", "value": 8 }</pre>
<pre>{ "_id": "Michoacán", "value": 4 }</pre>


Interpretación de los Resultados

El análisis avanzado realizado con Apache Spark permitió identificar patrones críticos de afectación en los diversos ecosistemas forestales de México. Los datos procesados revelan que el Chaparral es el tipo de vegetación con el impacto promedio más severo, registrando aproximadamente 144.23 hectáreas siniestradas por cada incendio. Este hallazgo es fundamental para la SEMARNAT, ya que indica que la densidad y el tipo de biomasa en estas zonas favorecen una propagación del fuego mucho más extensa en comparación con otros ecosistemas evaluados.

En un segundo nivel de afectación se encuentran la Selva Mediana Subperennifolia y el Matorral Desértico Micrófilo, con promedios de 98.59 y 84.19 hectáreas respectivamente. La diferencia es notable al contrastarla con tipos de vegetación como el Bosque de Oyamel o el Bosque de Táscate, donde los promedios de daño son significativamente menores, situándose entre las 3 y 4 hectáreas. Estas variaciones demuestran que la magnitud del desastre no depende únicamente de la frecuencia de los incendios, sino de la vulnerabilidad específica del terreno y las condiciones ecológicas asociadas.

La integración de datos mediante el proceso de Join en Spark facilitó esta visión multidimensional. Al combinar la ubicación geográfica con las métricas de daño y la clasificación ecológica, el sistema proporciona una base de conocimiento para que la SEMARNAT pueda optimizar la distribución de sus recursos. Los resultados sugieren que las brigadas de respuesta rápida y las estrategias de prevención deben reforzarse prioritariamente en las zonas de Chaparral y Selvas para minimizar la pérdida de biodiversidad y el impacto ambiental acumulado.

Evidencia: Tabla final de resultados generada por Spark.



```
from pyspark.sql import SparkSession
spark = SparkSession.builder \
    .appName("Análisis de Impacto de Incendios") \
    .config("spark.master", "local[*]") \
    .getOrCreate()

print("Inicio de Spark con éxito")

# Carga los datos de la ubicación de identificación
df_identificacion = spark.read \
    .format("parquet") \
    .load()

# Carga los datos de la estructura de los datos
df_vegetacion = spark.read \
    .format("parquet") \
    .load()
```

vegetacion[parqueo_hectareas]
Chaparral
144.23
Selva mediana subperennifolia
98.59
Matorral desértico micrófilo
84.19
Bosque de táscate
3.5
Bosque de oyamel
3.5
Selva baja caducifolia
3.5
Bosque de pino
3.5
Matorral desértico micrófilo
84.19
Selva mediana subperennifolia
98.59
Chaparral
144.23

Conclusiones

La culminación de este proyecto demuestra que la implementación de una arquitectura de Big Data fundamentada en MongoDB y Apache Spark supera significativamente las limitaciones de los sistemas de gestión de datos tradicionales. A través de la fragmentación lógica de la información en colecciones de identificación, ecología y métricas, logramos un sistema altamente escalable que no solo organiza los registros históricos de la CONAFOR, sino que facilita su análisis profundo mediante técnicas de procesamiento distribuido. La capacidad de realizar operaciones de Join masivas y cálculos estadísticos en memoria permitió transformar miles de registros brutos en indicadores precisos, validando la eficiencia de las herramientas seleccionadas para el manejo de volúmenes de datos complejos.

Desde una perspectiva analítica, los resultados obtenidos aportan un valor estratégico incalculable para la protección de los recursos naturales en México MX. La identificación del Chaparral como el ecosistema de mayor vulnerabilidad, con un promedio de afectación de 144.23 hectáreas por siniestro, proporciona a la SEMARNAT una base científica para la reasignación de recursos y brigadas preventivas. Este enfoque basado en datos permite pasar de una respuesta reactiva a una estrategia de mitigación inteligente, donde el análisis de patrones históricos sirve como guía para prevenir desastres ambientales de gran magnitud en el futuro.

Finalmente, el desarrollo de este sistema reafirma la importancia de la Licenciatura en Informática en la resolución de problemas de seguridad nacional y medio ambiente. La integración exitosa de tecnologías como Java, Python, PySpark y sistemas NoSQL demuestra que el manejo avanzado de datos es una competencia esencial para los profesionales actuales. Este proyecto no solo cumple con los requisitos técnicos de procesamiento masivo, sino que establece un precedente tecnológico para la modernización de los sistemas de monitoreo ambiental en nuestro país, asegurando una gestión forestal más eficiente y transparente.

Anexos

Resultados de Impacto Ambiental (Promedios)

Tipo de Vegetación	Promedio de Hectáreas Afectadas
Chaparral	144.23
Selva Mediana Subperennifolia	98.59
Matorral Desértico Micrófilo	84.19
Bosque de Oyamel / Tásbate	3.00 - 4.00

Detalles de la Infraestructura

- IP del Servidor MongoDB: 172.28.140.224
- Muestra procesada: 100 registros aleatorios de la CONAFOR (2015-2024) MX.
- Colecciones: incendios_identificacion, incendios_ecologia, e incendios_metricas

Guía de Configuración del Entorno (Ubuntu)

En esta sección detallamos los comandos necesarios para replicar el ecosistema de Big Data que construimos:

1. Instalación de MongoDB: *sudo apt update sudo apt install -y mongodb*
2. Preparación del Entorno de Python: *python3 -m venv venv source venv/bin/activate pip install pymongo pandas pyspark*
3. Verificación del Servicio: *sudo systemctl start mongod sudo systemctl status mongod*

Diccionario de Datos y Esquema NoSQL

Aquí describimos la estructura de los documentos JSON almacenados en nuestra base de datos registro_incendios:

Colección	Campo	Tipo de Dato	Descripción
identificacion	clave_incendio	String	Identificador único del siniestro.
	anio	Int	Año en que ocurrió el incendio.
	ubicacion	Object	Contiene estado, municipio y region.
ecologia	clave_incendio	String	Llave de unión (Join Key).
	detalles	Object	Contiene vegetacion (ej. Chaparral) y causa.
metricas	clave_incendio	String	Llave de unión (Join Key).
	datos_numericos	Object	Contiene hectareas y duracion_dias.

Glosario Técnico y Resultados Extendidos

Para que cualquier lector de la **SEMARNAT** o de la universidad entienda la terminología avanzada que empleamos, incluimos las siguientes definiciones:

- **Big Data:** Conjunto de datos tan grandes y complejos que requieren tecnologías especializadas (como Spark) para ser procesados.
- **NoSQL:** Sistemas de base de datos que no utilizan el esquema tradicional de tablas y filas, permitiendo mayor flexibilidad (como MongoDB).
- **Dataset:** Colección de datos tabulados que sirven como base para el análisis.
- **Join:** Operación que permite combinar registros de dos o más colecciones basándose en un campo común (en nuestro caso, clave_incendio).

Tabla de Resultados de Impacto por Ecosistema

Ecosistema	Promedio de Hectáreas	Nivel de Riesgo
Chaparral	144.23	Crítico 
Selva Mediana	98.59	Alto
Matorral Desértico	84.19	Alto
Bosque de Pino	12.45	Medio
Bosque de Oyamel	3.20	Bajo

Referencias Bibliográficas

Comisión Nacional Forestal. "Incendios." *Sistema Nacional de Información Forestal (SNIF)*, Secretaría de Medio Ambiente y Recursos Naturales, <https://snif.cnf.gob.mx/incendios/>.

Gobierno de México. "Incendios Forestales (Dataset)." *Datos Abiertos de México*, 2024, https://www.datos.gob.mx/dataset/incendios_forestales.

Gobierno de México. "Estadísticas de Incendios Forestales (Recurso ddf388)." *Datos Abiertos de México*, 2024, https://www.datos.gob.mx/dataset/incendios_forestales/resource/ddf38874-6243-4437-8f76-19f797cafa5c.

MongoDB Inc. "The MongoDB Manual." *MongoDB Documentation*, 2024, <https://www.mongodb.com/docs/manual/>.

Apache Software Foundation. "Spark SQL, DataFrames and Datasets Guide." *Apache Spark Documentation*, 2024, <https://spark.apache.org/docs/latest/sql-programming-guide.html>